

Deepseek V4 性能瓶颈排查

flash-fp8

1. 性能对比及json文件

@dpsk-V4 nmz1101 & H20 内部测试

 H20-tp1.json.gz
65.64MB



 nmz-tp1.json.gz
301.24MB



2. 性能瓶颈分析

基于SELECT name,COUNT(*) AS record_count,SUM(dur) / 1000000.0 AS total_duration_ms, SUM(dur) / COUNT(*) / 1000000.0 AS avg_duration_ms FROM slice WHERE category IN('kernel', 'gpu_memcpy', 'gpu_memset') GROUP BY name ORDER BY total_duration_ms DESC;生成算子级 prof表格

 nmz1101.tsv
37.02KB



 h20.tsv
36.41KB



经对比发现 瓶颈主要在以下几个部分：

2.1 量化 GEMM 算子

H20: per_token_group_quant_8bit_kernel(avg 0.0014ms) + cutlass_3x_gemm_fp8_blockwise/_w8a8_block_fp8_matmul(avg 0.005-0.012ms)

BW1101: _per_token_quant_int8(avg 0.0118ms)+ Cijk_*_Squant类算子 (avg 0.0049-0.0729ms)

尽管H20调用次数更高 但是总耗时短 $0.0014\text{ms} \times 9009\text{次} \approx 12.5\text{ms}$

BW1101上 $0.0118\text{ms} \times 3481\text{次} \approx 41.1\text{ms}$

2.2 MLA / Flash Attention 算子

sparse_fp8 flash decode kernel在H20上和NMZ上的平均耗时是0.033ms和0.098ms 慢了三倍
flash_fwd_mla_combine_kernel在H20上和NMZ上的平均耗时是0.0027ms和0.0796ms 慢了29倍
paged_mqa_logits_fp8算子在H20上没有耗时 在nmz上平均耗时0.483ms 而且调用了1701次

2.3 elementwise

elementwise_kernel & vectorized_elementwise_kernel 慢2倍多

2.4 MoE

moe_align_block_size在H20上平均0.003828ms 调用次数3483 总耗时13.334989ms
在nmz上平均耗时0.008412 调用次数3483 总耗时29.302082
除此之外 两者 MoE 实现策略不同 H20 用大融合 kernel fused_moe_kernel平均耗时 0.101652ms 调用次数6966 总耗时708.111864ms 是H20号是最大的算子
DCU 用多了很多带有marlin名的小算子

将以上内容整理成表格形式：

bw1101 vs h20					
设备	算子名	次数	耗时	平均耗时	bw1101/h20
h20	gemm	15959	21.83842	0.001368408	7.004039226
bw1101		12148	116.431071	0.009584382	
h20	elementwise	14004	38.0378	0.00271621	2.588650972
bw1101		40902	287.595	0.007031319	
h20	MLA&FA	4641	118.021	0.02543008	8.744756975
bw1101		5265	1170.83	0.222379867	
h20	MoE	3483	13.334989	0.003828593	1.704701484
bw1101		10448	68.19	0.006526608	